

Детекција AI-генерисаних слика помоћу дубоких неуронских мрежа и анализа њихових одлука: ResNet и ViT

Кристина Попов
Факултет техничких наука
Универзитет у Новом Саду
Нови Сад, Србија
E2 93/2024

Тина Михајловић
Факултет техничких наука
Универзитет у Новом Саду
Нови Сад, Србија
R2 21/2024

Сажетак—Развој савремених генеративних модела као што су *Stable Diffusion*, *DALL-E* и *Midjourney*, довео је до унапређења квалитета синтетичких слика. Због тога постаје све теже разликовати слике које је креирао човек од оних које је генерисала вештачка интелигенција (AI).

У раду се испитује бинарна класификација слика на стварне (слике креиране од стране човека) и AI-генерисане применом дубоких неуронских мрежа. Поређење обухвата конволуционе мреже (CNN) и *Vision Transformer* (ViT) моделе за препознавање синтетичких слика.

Експерименти су спроведени на јавном скупу података. Примењени су *transfer learning* и *fine-tuning* модела ResNet-50 и ViT-Small. Перформансе модела су евалуиране коришћењем метрика прецизности, одзива, F1 мере и ROC-AUC криве.

Додатно, примењене су технике *Explainable AI* (XAI) ради анализе процеса класификације. За модел ResNet-50 коришћен је метод Grad-CAM, док су за *Vision Transformer* анализирани Grad-CAM и *Attention Rollout*. Ови приступи омогућавају увид у просторне и семантичке карактеристике слика на које се модели ослањају приликом доношења одлука.

Резултати указују на разлике у тачности и интерпретабилности између модела, као и на разлике у обрасцима на које се модели фокусирају.

I. Увод

Брз напредак генеративних модела, као што су *Stable Diffusion* [1], *Midjourney* [2] и *DALL-E* [3], довео је до значајног повећања веродостојности вештачки генерисаних слика. Разликовање овако генерисаних слика од стварних фотографија постаје све тежи проблем. Последиčno, аутоматска детекција AI-генерисаног садржаја представља кључан изазов у областима попут одржавања интегритета дигиталних медија, борбе против дезинформација и очувања поверења у визуелне податке. Истраживања показују да чак и људски посматрачи често имају потешкоћа да поуздано разликују стварне и синтетичке слике [4].

Проблем детекције AI-генерисаних слика је важан не само са техничког, већ и са друштвеног аспекта. Широка доступност генеративних алата омогућава масовно креирање уверљивог синтетичког садржаја. Тиме се развија неповерљивост ка аутентичности садржаја, а честе су и

злоупотребе попут ширења лажних вести и крађе идентитета. Због тога су робусни системи за аутоматску детекцију неопходни као допуна људској процени и као механизам за очување поузданости дигиталних система. [5] [6]

Досадашњи радови се углавном фокусирају на једну архитектуру неуронских мрежа, без директног поређења фундаментално различитих приступа [7] [8]. Такође, постојеће методе често не пружају довољно увида у начин доношења одлука модела, што отежава интерпретацију резултата и смањује сигурност у кредибилитет система [9].

У овом раду приступамо проблему детекције AI-генерисаних слика кроз компаративну анализу две архитектуре дубоких неуронских мрежа: конволуционе неуронске мреже (ResNet50 [10]) и трансформер архитектуре (*Vision Transformer*, ViT [11]). Поред евалуације перформанси коришћењем стандардних квантитативних метрика, уводимо и методе објашњиве вештачке интелигенције (*Explainable AI*, XAI) како бисмо даље анализирали и поредили понашање модела. Конкретно, примењујемо Grad-CAM за обе архитектуре [12] [13] и *Attention Rollout* [14] за ViT модел, са циљем идентификације делова слике који утичу на одлуку модела.

II. Релавантна литература

Рад [17] показује да конволуционе неуронске мреже могу успешно да детектују AI-генерисане слике, при чему се користи *transfer learning* приступ заснован на моделима као што је ResNet50. У овом раду, врши се додатно прилагођавање већ обучених мрежа, што омогућава да дубљи слојеви уче суптилне обрасце карактеристичне за синтетички садржај. Додатно, рад [18] указује да плитки слојеви мреже углавном уче опште визуалне карактеристике, док дубљи слојеви хватају специфичне обрасце и неправилности. Ови налази су нас мотивисали да применимо стратегију парцијалног одмрзавања слојева, конкретно дубљих слојева, како би модел могао боље да детектује AI-генерисане слике.

Рад [15] показује да комбинација претходно обучених тежина, аугментације података и регуларизације (нпр. *dro-*

prompt) значајно побољшава перформансе модела, при чему ViT надмашује CNN базне моделе. Посебно се истиче значај величине закрпа (*patch*), где конфигурација 16×16 даје најбољи баланс између резолуције карактеристика и ефикасности. Даља истраживања потврђују да је избор величине закрпа важан хиперпараметар, при чему мање закрпе омогућавају бољу детекцију локалних карактеристика релевантних за детекцију синтетичког садржаја, док веће закрпе доводе до значајног пада перформанси (и до $\sim 15\%$ у F1 мери) [16]. Ово указује да резолуција репрезентације има већи утицај на тачност него сама величина модела. Поред тога, рад [8] показује да средњи слојеви ViT модела понекад дају боље резултате од последњих слојева у задацима детекције AI-генерисаних слика. Ови налази су директно утицали на дизајн наших експеримената, укључујући избор величине закрпа, примену аугментације, као и испитивање перформанси различитих трансформер слојева.

Рад [4] упоређује стварне и AI-генерисане слике са циљем да укаже на карактеристике на које људско око треба да обрати пажњу приликом њиховог разликовања. Овај приступ нас је мотивисао да применимо објашњиве моделе како бисмо проверили да ли се фокус модела поклапа са визуелним траговима које људи користе за препознавање синтетичког садржаја.

III. Методологија

A. Скуп података

У раду је коришћен јавно доступан скуп података ¹ који садржи укупно 60 000 слика, равномерно распоређених на две класе: *Real* и *Fake*, тј. стварне и AI-генерисане слике. Обе класе обухватају различите домене визуелних сцена, укључујући уметничке портрете, пејзаже и објекте.

Класа *Real* обухвата 30 000 слика, при чему је 22 500 слика прикупљено са платформи *Pexels* и *Unsplash*, док је преосталих 7 500 слика преузето из базе *WikiArt*.

Класа AI-генерисаних слика такође садржи 30 000 слика, од којих је 10 000 генерисано помоћу модела *Stable Diffusion*, 10 000 помоћу *MidJourney* модела и 10 000 помоћу DALL-E модела.

Разноврсност извора стварних и синтетичких слика доприноси бољој генерализацији тренираних модела.

B. Подела података

Из обе класе је издвојено по 8 000 слика. На тај начин формиран је уравнотежен скуп података од 16 000 слика погодан за ефикасно тренирање и евалуацију модела. Овај подскуп је изабран као свесна дизајн одлука. Циљ је омогућавање бржих итерација током тренинга и ефикасније подешавање модела, имајући у виду ограничење доступних рачунарских ресурса.

Над овим скупом примењена је стратификована подела у односу 70% / 10% / 20%. Тиме су образовани тренинг, валидациони и тест скуп коришћени за учење модела, подешавање хиперпараметара и евалуацију, редом.

¹Kaggle скуп података

C. Претпроцесирање података

Претпроцесирање података обухвата припрему слика за улаз у дубоке неуронске мреже. Све слике су прво конвертоване у RGB формат и скалиране на резолуцију од 224×224 пиксела.

На скуп за тренирање примењене су технике аугментације података ради повећања робусности модела и побољшања способности генерализације на непознате податке. Ове технике укључују насумично хоризонтално пресликавање, ротацију до 20 степени, промене у осветљењу, контрасту и засићењу, као и примену *Gaussian blur* филтера и конверзију у сиве тонове. Поред тога, примењен је и *RandomResizedCrop* како би се модел изложио различитим деловима слике.

Након аугментације, слике су конвертоване у тензоре, при чему су вредности пиксела нормализоване коришћењем стандардних параметара (ImageNet [19] статистика), чиме се убрзава конвергенција током тренинга.

На валидациони и тест скуп примењена је само конверзија у тензоре и нормализација.

D. Модел

У овом раду примењене су две архитектуре дубоких неуронских мрежа за детекцију AI-генерисаних слика: конволуциона неуронска мрежа ResNet-50 и *Vision Transformer* (ViT-Small). Оба модела су иницијализована тежинама претходно обученим на скупу података *ImageNet* [19]. Након тога, примењен је приступ *transfer learning*-а у циљу прилагођавања модела задатку детекције AI-генерисаних слика.

1) *ResNet-50*: Архитектура ResNet-50 заснива се на резидуалном учењу, које омогућава тренирање дубоких мрежа смањењем утицаја проблема нестајања градијената. У оквиру овог рада, оригинални класификатор је уклоњен и замењен прилагођеним класификатором. Он се састоји од *fully connected* слоја са 512 неурона, *ReLU* активационе функције и *dropout* регуларизације. На крају, примењен је излазни слој са једним неуроном за бинарну класификацију.

Током *fine-tuning*-а, поређени су приступи рада са потпуно замрзнутом ResNet-50 основом и одмрзнутим дубљим конволуционим слојевима

Поред тога, извршена је и систематска претрага хиперпараметара како би се одредила најбоља конфигурација модела. Претраживане су различите комбинације слојева који се одмрзавају, вредности *dropout* регуларизације, као и примена *learning rate scheduler*-а. Величина (*batch size*) постављена је на 32.

2) *Vision Transformer (ViT)*: Архитектура *Vision Transformer* (ViT) заснива се на примени трансформер модела на визуелне податке, при чему се улазна слика дели на фиксне закрпе (*patch*) који се даље обрађују као низ токена.

У овом раду коришћен је модел *vit_small_patch16_224*, претходно обучен на ImageNet скупу података. Оригинални класификациони слој модела је уклоњен, а уместо њега

додат је прилагођени излазни слој који се састоји од *fully connected* слоја са два неурона, прилагођеног бинарној класификацији.

За разлику од конволуционих мрежа, ViT модел омогућава моделовање глобалних зависности у слици кроз механизам самопажње (*self-attention*). Ово је посебно релевантно у контексту детекције AI-генерисаних слика, где локални артефакти често нису довољни, већ је неопходно уочити глобалне неконзистентности.

Током *fine-tuning*-а испитивани су различити приступи прилагођавања модела, укључујући тренинг само класификационе главе, као и фино подешавање свих параметара модела. Анализиран је и утицај избора CLS токена из различитих трансформер блокова на перформансе класификације.

E. Процес тренирања

Током тренирања, модели су након сваке епохе евалуирани на валидационом скупу. Као критеријум за избор најбољег модела коришћена је ROC-AUC метрика, с обзиром на њену погодност за процену перформанси бинарних класификатора.

На основу резултата на валидационом скупу вршен је избор оптималних хиперпараметара. Коришћењем ROC-AUC криве одређена је оптимална вредност граничног прага (*threshold*) за класификацију, која максимизује перформансе модела. Тако одређен праг је затим примењен током евалуације на тест скупу, како би се обезбедила конзистентна и објективна процена коначних резултата.

За избор најбоље конфигурације примењен је и рани зауставни критеријум (*early stopping*).

F. Евалуационе метрике

За евалуацију модела коришћене су следеће метрике: тачност, прецизност, одзив, F1 мера и ROC-AUC.

Тачност представља проценат исправно класификованих узорака. Прецизност мери удео тачно позитивних предикција међу свим позитивно класификованим примерима, док одзив указује на способност модела да открије све позитивне узорке. F1 мера представља хармонијску средину прецизности и одзива и користи се као балансирана метрика у случају неуравнотежених класа. ROC-AUC описује способност модела да разликује класе независно од изабраног прага одлуке.

G. Анализа одлука модела

У циљу бољег разумевања начина на који модели доносе одлуке, извршена је анализа делова слике који имају највећи утицај на класификацију. У ту сврху примењене су методе визуелизације прилагођене различитим архитектурама. За ResNet-50 модел коришћен је Grad-CAM, док су за Vision Transformer модел анализирани Attention Rollout и Grad-CAM варијација за ViT.

Grad-CAM користи градијенте циљне класе у односу на активације последњег конволуционог слоја. На основу тих градијената израчунавају се тежине које показују значај



Слика 1. Пример Grad-CAM и Attention Rollout визуелизација.

појединих карактеристика. Затим се формира топлотна мапа. Она приказује регионе слике који највише утичу на одлуку модела. Важнији делови су означени топлим бојама (жута и црвена), док су мање значајни региони приказани хладнијим бојама (плава). Grad-CAM је примењен над последњим конволуционим слојем модела ResNet-50. За сваку улазну слику израчуната је топлотна мапа, која је затим интерполирана на оригиналну резолуцију и визуелно преклопљена са улазном сликом (Слика 1).

За ViT модел примена класичног Grad-CAM-a није директна, због одсуства конволуционих слојева и експлицитне просторне структуре карактеристика. Због тога је коришћена прилагођена варијанта Grad-CAM-a, која се примењује над активацијама и градијентима *norm1* слоја претпоследњег трансформер блока, а затим трансформише у просторну мапу.

Поред тога, примењен је и Attention Rollout, који анализира матрице пажње (*attention*) кроз свих 12 трансформер блокова и омогућава праћење протока информације од улазних (*patch*) токена до последњег CLS токена.

Комбинација ове две методе омогућава свеобухватнију анализу понашања ViT модела: Grad-CAM пружа локалну интерпретацију битних региона, док Attention Rollout даје увид у глобалну структуру пажње. Овај комбиновани приступ је посебно важан у контексту детекције AI-генерисаних слика, где су релевантни и локални артефакти и глобалне неконзистентности.

IV. Резултати

A. ResNet-50


Резултати експеримената показују да је најбоља конфигурација постигнута при одмрзавању слојева *layer3* и *layer4*, уз *dropout* вредност 0.6 и без примене *scheduler*-a. Ова комбинација је остварила највишу ROC-AUC вредност на валидационом скупу у односу на све остале испробане конфигурације.

Током процеса тренирања модела ResNet-50 уочен је брз пораст перформанси већ у раним епохама. Вредност ROC-AUC метрике на тренинг скупу порасла је са 0.8112 у првој епохи на преко 0.92 већ након пете епохе. На валидационом скупу забележен је пораст са 0.9027 на 0.9434 у истом интервалу. У средњој фази тренирања (6–12 епохе) валидациони ROC-AUC достиже вредности ~ 0.9557 , уз смањење разлике између тренинг и валидационог скупа са -0.0914 на ~ -0.004 . Овакав тренд указује на стабилно и уравнотежено учење без *overfitting*-a. У каснијим епохама

(13–17 епохе) примећене су благе осцилације без значајног побољшања, при чему је најбоља вредност валидационог ROC-AUC-а износила 0.9602. Применом механизма *early stopping* тренинг је прекинут у 20. епохи, након што није дошло до побољшања у три узастопне епохе. Током целог процеса није уочен изражен *overfitting*, будући да је разлика између тренинг и валидационог ROC-AUC-а остала мала (до ~ 0.0076 у завршним епохама).

На тест скупу, модел постиже следеће резултате: тачност од 0.8991, прецизност 0.8858, одзив 0.9163 и F1 меру 0.9008. Вредност ROC-AUC метрике износи 0.9593, што указује на високу способност модела да разликује стварне и AI-генерисане слике. Добијени резултати потврђују да модел успешно генерализује на невиђеним подацима и омогућава поуздану бинарну класификацију.

Матрица конфузије приказана на Слици 2 даје детаљан увид у перформансе модела на тест скупу. Од укупног броја стварних (*Real*) слика, модел је исправно класификовао 1411, док је 189 погрешно означено као AI-генерисано (*Fake*). Са друге стране, од AI-генерисаних слика, 1466 је исправно препознато, док је 134 класификовано као *Real*.



Слика 2. Матрица конфузије ResNet-50 (лево) и ViT-Small (десно) модела на тест скупу.

Ови резултати указују да модел показује нешто бољу способност препознавања AI-генерисаних слика у односу на стварне, што је у складу са мало већим вредностима одзива за ту класу. Упркос томе, број погрешних класификација је релативно низак.

B. ViT-Small

Модел ViT-Small постигао је високе перформансе у задатку детекције AI-генерисаних слика, а оптимална конфигурација постигла је резултате приказане у Табели I.

Упоређене стратегије тренирања показују да *fine-tuning* значајно надмашује *linear probing*, са разликом од приближно 10-12% у F1 мери (око 0.93 наспрам ~ 0.82). Додатно, анализа различитих трансформер слојева показује да средњи слојеви (нпр. слој 6) дају боље резултате на мањим скуповима (F1 ~ 0.84), док дубљи слојеви (слој 12) постижу најбоље перформансе на већим скуповима (F1 ~ 0.93), што указује на постепено формирање дискриминативних карактеристика са дубином модела.

Табела I

Поређење перформанси ResNet-50 и ViT-Small модела на тест скупу

Метрика	ResNet-50	ViT-Small
тачност	0.8991	0.9322
прецизност	0.8858	0.9447
одзив	0.9163	0.9181
F1 мера	0.9008	0.9312
ROC-AUC	0.9593	0.9824

Анализа хиперпараметара показује да мања стопа учења ($2 \cdot 10^{-5}$) доводи до стабилније конвергенције и боље генерализације (F1 ~ 0.93 у односу на ~ 0.92), док већи *batch size* (32) доприноси стабилности тренинга и побољшању перформанси. Оптимизација граничног прага (0.55-0.60) доводи до конзистентног, али не и драстичног побољшања F1 мере (до $\sim 1\%$).

Кључно запажање односи се на динамику тренирања: модел достиже најбоље валидационе перформансе већ у првих 1-5 епоха, након чега долази до стагнације или благог пада. Ово указује на брзу адаптацију претходно обучених репрезентација, при чему класификациона глава и последњи слојеви ефикасно усвајају задатак. Продужено тренирање доводи до раста перформанси на тренинг скупу без побољшања на валидационом, што указује на појаву *overfitting*-а и оправдава примену раног заустављања.

У целини, резултати показују да ViT модел, уз адекватан *fine-tuning*, избор слоја и подешавање прага, представља ефикасан приступ за детекцију AI-генерисаних слика, уз брзу конвергенцију и високе перформансе на тест скупу.

C. Квантитативно поређење модела

Оба модела постижу високе перформансе у задатку бинарне класификације, али уз јасне разлике у нивоу тачности и равнотежи између класа (Табела I).

Посматрано по класама, ResNet-50 показује боље перформансе у детекцији *Fake* слика (F1 ~ 0.900) у односу на *Real* (F1 ~ 0.897), што указује на већу осетљивост на карактеристичне артефакте синтетичких слика. Са друге стране, ViT-Small модел постиже уједначеније резултате (F1 ~ 0.933 за *Real* и ~ 0.931 за *Fake*), што указује на бољу равнотежу између прецизности и одзива, као и мању склоност ка пристрасности према једној класи.

Анализа матрице конфузије додатно потврђује ове налазе. ResNet-50 прави већи број лажно позитивних класификација (*Real* $\rightarrow$ *Fake*), што утиче на смањење прецизности за класу *Real*. Насупрот томе, ViT-Small модел смањује број оваквих грешака, што доводи до побољшања укупне F1 мере и стабилнијег понашања модела.


Разлика у перформансама може се повезати са архитектурским карактеристикама модела. Док ResNet-50 преваходно екстрахује локалне карактеристике (текстуре и артефакте), ViT-Small захваљујући механизму пажње ефикасније моделира глобалне односе у слици. Тиме се омогућава боље уочавање суптилних разлика између стварних и

AI-генерисаних слика, посебно у случајевима где локални артефакти нису довољни за поуздану класификацију.

Дакле, ViT-Small модел показује конзистентно боље перформансе у релевантним метрикама, уз већу стабилност и бољу генерализацију. Иако ResNet-50 остаје конкурентан и поуздан, нарочито у детекцији изражених синтетичких артефаката, резултати овог рада указују да трансформер приступ представља адекватније решење за дати задатак.

D. Квалитативна анализа модела заснована на XAI методама

Квалитативна анализа је спроведена кроз четири карактеристична случаја. Циљ је да се упореди начин на који ResNet-50 и ViT-Small модели доносе одлуке. Визуализације анализираних случајева приказане су на Слици 3.



Слика 3. Визуална анализа резултата

У случајевима када су оба модела тачно класификовали слику (први ред), уочава се да оба приступа издвајају релевантне регионе објекта. ResNet-50 показује концентрисан фокус на локалне текстурне карактеристике, док ViT распоређује пажњу шире, обухватајући глобалну структуру слике. *Attention rollout* додатно потврђује да ViT модел користи просторни контекст целе слике.

У случају када оба модела греше (други ред), топлотне мапе указују на расут фокус. Оба модела усмеравају пажњу ка мање релевантним деловима слике, што сугерише да визуелни сигнал није довољно дискриминативан.

Када ViT модел успешно класификује слику, а ResNet-50 греша (трећи ред), приметно је да ViT фокусира пажњу на кључне делове објекта и њихове међусобне односе, док ResNet-50 остаје усмерен на ограничене локалне регионе. Ово запажање иде у корист претпоставки да је глобална анализа слике важна за исправну класификацију.

Супротно томе, у случајевима где је ResNet-50 класификација тачна, а ViT греша (четврти ред), ResNet јасно

издваја fine локалне карактеристике, док ViT распоређује пажњу дифузно и без фокуса. Последиčno, ViT не успева да изолује критичне визуелне дискриминаторе. Дакле, CNN модели могу бити робуснији када су локални артефакти кључни за детекцију.

V. Закључак и Дискусија

Показано је да ResNet-50 и ViT-Small користе различите стратегије за детекцију синтетичких слика: CNN се ослања на локалне текстуре и артефакте, док ViT модел користи глобалне односе и контекст. Последиčno, долази до карактеристичних грешака и уочених разлика у перформансама ова два модела.

ResNet-50 показује предност у ситуацијама где су локалне неправилности, шум или текстурни артефакти кључни за разликовање класа. Његова способност да детектује суптилне локалне сигнале чини га робусним у случајевима изражених синтетичких карактеристика. Међутим, овај приступ може довести до погрешних класификација када локални детаљи нису довољно информативни или када је потребно разумевање ширег контекста слике.

Са друге стране, ViT-Small модел показује боље укупне перформансе и стабилнију генерализацију, захваљујући способности да моделује глобалне односе унутар слике. Ово му омогућава да успешно класификује комплексније и суптилније примере, али истовремено може довести до расутог фокуса и пропуштања локалних артефаката у одређеним случајевима.

Оба приступа постижу задовољавајуће резултате на задатку детекције синтетичких слика, чак и када су тернирана на ограниченом скупу од свега 16 000 примера.

VI. Даљи рад

У експерименталној евалуацији уочено је да и ResNet-50 и ViT-Small модели чешће греше код класификације слика на којима су приступи људи. Грешке су посебно изражене на фотографисаним лицима, а мање на уметничким (насликаним) портретима. Претпоставља се да је ово последица садржаја скупа података, где је у првих 16 000 слика већи број појава људи на синтетичким него на стварним сликама. Као даљи правац истраживања, предлаже се проширење скупа података већим бројем стварних слика које садрже људе, како би се побољшала робусност и способност генерализације модела. Повећање обима и разноврсности података може допринети и ублажавању појаве *overfitting*-а, посебно код ViT модела.

Такође, вреди даље анализирати технике аугментације података. Показано је да аугментација значајно утиче на перформансе модела. Проналазак оптималне конфигурације би додатно унапредио добијене резултате.

Занимљиво би било истражити и алтернативне начине визуализације процеса одлуке ViT модела, те даље усавршити закључке и интерпретабилност резултата.

Литература

- [1] ROMBACH, Robin, et al. High-resolution image synthesis with latent diffusion models. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022. p. 10684-10695.
- [2] MidJourney, "MidJourney," [Online]. Available: <https://www.midjourney.com/>
- [3] RAMESH, Aditya, et al. Zero-shot text-to-image generation. In: International conference on machine learning. Pmlr, 2021. p. 8821-8831.
- [4] KAMALI, Negar, et al. How to distinguish AI-generated images from authentic photographs. arXiv preprint arXiv:2406.08651, 2024.
- [5] CHESNEY, Robert; CITRON, Danielle. Deepfakes and the new disinformation war: The coming age of post-truth geopolitics. Foreign Aff., 2019, 98: 147.
- [6] VERDOLIVA, Luisa. Media forensics and deepfakes: an overview. IEEE journal of selected topics in signal processing, 2020, 14.5: 910-932.
- [7] WANG, Sheng-Yu, et al. CNN-generated images are surprisingly easy to spot... for now. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020. p. 8695-8704.
- [8] PARK, NaHyeon, et al. Rethinking the Use of Vision Transformers for AI-Generated Image Detection. arXiv preprint arXiv:2512.04969, 2025.
- [9] DOSHI-VELEZ, Finale; KIM, Been. Towards a rigorous science of interpretable machine learning. arXiv preprint arXiv:1702.08608, 2017.
- [10] HE, Kaiming, et al. Deep residual learning for image recognition. In: Proceedings of the IEEE conference on computer vision and pattern recognition. 2016. p. 770-778.
- [11] DOSOVITSKIY, Alexey, et al. An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929, 2020.
- [12] SELVARAJU, Ramprasaath R., et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. In: Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017.
- [13] CHEFER, Hila; GUR, Shir; WOLF, Lior. Transformer interpretability beyond attention visualization. In: Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021. p. 782-791.
- [14] ABNAR, Samira; ZUIDEMA, Willem. Quantifying attention flow in transformers. In: Proceedings of the 58th annual meeting of the association for computational linguistics. 2020. p. 4190-4197.
- [15] LAMICHHANE, Darshan. Advanced detection of AI-generated images through vision transformers. TechRxiv. 2024.
- [16] H. WANG, "Vision Transformer-Based Framework for AI-Generated Image Detection in Interior Design," Informatica, vol. 49, no. 16, 2025, doi: 10.31449/inf.v49i16.7979.
- [17] XUAN, Xinsheng, et al. On the generalization of GAN image forensics. In: Chinese conference on biometric recognition. Cham: Springer International Publishing, 2019. p. 134-141.
- [18] YOSINSKI, Jason, et al. How transferable are features in deep neural networks? In: Advances in Neural Information Processing Systems (NeurIPS). 2014. p. 3320-3328.
- [19] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, L. Fei-Fei, "ImageNet: A Large-Scale Hierarchical Image Database," IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2009.